[보고서] 논문 리뷰 결과 및 실험 설계 수정안

주제: 시스템 프롬프트 지시 준수 붕괴 조건 분석 및 실험 설계 고도화

---

1. 선행 논문 리뷰

선행 논문들을 리뷰하는 과정에서, 기존 주제였던 **"Multi-turn 환경에서 System Prompt가 붕괴되는 시점"**에 대해 방향을 일부 수정해야 한다고 판단했습니다. Multi-turn에서의 대화 횟수는 결국 전체 context size에 포함되는 변수입니다. 턴이 늘면 토큰도 필연적으로 증가하므로, 대화 횟수와 턴당 토큰 수는 모두 context size로 귀결되기 때문입니다. 이 두 변수를 억지로 분리하면 실험이 인위적이 되므로, 대화 횟수를 주 독립변수로 유지하되 매 턴마다 누적 토큰 수를 동시에 기록하는 방식으로 설계하겠습니다.

이에 따라 주제의 방향을 **"시스템 프롬프트의 지시 준수가 어떤 조건에서 붕괴하는가"**로 조정하고, 핵심 변수(규칙 개수, 대화 횟수, 공격 강도)를 기준으로 논문들을 다음과 같이 분류하였습니다.

관련 논문 (유지)

논문 ID	주요 문헌	출처	핵심 기여 및 변수 근거
A	"Do Anything Now"	Shen et al., CCS 2024	**공격 강도** 변수 근거 (탈옥 1,405건 분석, 최대 성공률 95%)
B	"Prompt Leakage"	Agarwal et al., EMNLP 2024	**대화 횟수** 변수 근거 (2턴 만에 ASR 17.7% → 86.2%)
C	"ECLIPTICA"	Wanaskar et al., arXiv 2026.01	**규칙 준수 측정** 방법론 근거 (86.7% 정렬 효율)
D	"Attention Tracker"	Hung et al., NAACL 2025	**공격 탐지 방법론** 참고 (AUROC 0.98~1.00)

비관련 논문 (제외) - 이쪽은 안보셔도 됩니다.

- **"Self-Improvement Towards Pareto Optimality"**: 학습 시점의 다목적 최적화로, 추론 시점의 시스템 프롬프트 준수와 무관.
- **"RLNVR"**: 보상 학습 방법론으로, 런타임 규칙 준수 측정과 직접적 연관성 낮음.
- **"ConflictScope" (Liu et al., 2025)**: LLM의 내재된 가치 우선순위 분석으로, 시스템 프롬프트 지시 준수와는 다른 층위의 문제.
- **"Lost in the Middle" (Liu 2023) / "What Works for..." (Gupte 2025)**: 정보 검색의 위치 편향 연구. 연구의 인접 분야이나 직접적인 선행 연구는 아니므로 배경 참고 문헌으로만 활용.

---

2. 관련 논문별 후속 연구 조사 및 시사점

[Paper A] 공격 기법의 진화: Multi-turn 및 자율 탈옥

1. **Crescendo (Russinovich et al., USENIX Security 2025)**

    - 무해한 질문으로 시작해 점진적으로 대화를 에스컬레이션하는 multi-turn 탈옥 기법.
    - GPT-4, Gemini 등에서 거의 100% ASR 달성 및 자동화 도구 공개.
2. **LRM 자율 탈옥 (Hagendorff et al., Nature Communications 2026.02)**
    - DeepSeek-R1, Gemini 2.5 Flash 등 추론 모델이 자율적으로 탈옥을 계획·실행 가능함을 입증 (97.14% ASR).
3. **종합 서베이 (2022-2025)**
    - 자동화된 공격은 오픈 모델(90-99%)과 상용 모델(80-94%) 모두에서 높은 성공률을 보임.

> [!TIP] **실험 설계 반영:** 기존 "노골적 직접 요청"에서 **"Crescendo 스타일의 점진적 에스컬레이션"**으로 공격 강도 변수를 수정합니다. 이는 최신 연구에서 가장 효과적이고 현실적인 공격 패턴임이 확인되었기 때문입니다.

[Paper B] 방어 기술의 발전 vs 준수 측정의 공백

1. **SysVec (2025.09)**: 시스템 프롬프트를 벡터로 인코딩하여 유출 원천 차단.
2. **ProxyPrompt (2025.05)**: 프록시 프롬프트 대체를 통해 94.7%의 추출 공격 방어.
3. **OWASP Top 10 2025**: *System Prompt Leakage*가 LLM07:2025로 공식 등재되어 산업 표준 위협으로 인정.

> [!IMPORTANT] **연구의 차별점:** 현재 후속 연구들은 모두 프롬프트 '유출(내용 추출)'에 집중하고 있습니다. **'규칙을 인지하고 있음에도 준수율이 저하되는 현상'**을 정량적으로 측정한 연구는 여전히 공백 상태이며, 이것이 본 연구의 핵심 가치입니다.

[Paper C] ECLIPTICA 후속 및 Gap 분석

- **ECLIPTICA (2026.01)**: 단일 규칙의 전환 효율을 측정하는 매우 최신 연구.
- **본 연구와의 차이**: ECLIPTICA는 한 번에 하나의 지시 변화를 다루지만, 본 연구는 **복수 규칙의 동시 준수**가 대화 진행에 따라 어떻게 무너지는지를 다룹니다.
- **미해결 질문**: "규칙이 여러 개일 때, 대화가 길어지면 어떤 규칙이 먼저 무너지는가?" → 본 연구가 채울 주요 Research Gap입니다.

---

3. 후속 연구 반영 실험 설계 수정안

연구가 채울 Gap (Problem Statement)

- [ ] 복수 규칙의 동시 준수율이 대화 진행에 따라 어떻게 붕괴하는가?
- [ ] 규칙 개수가 늘어나면 붕괴가 가속되는가?
- [ ] 점진적 에스컬레이션 공격 하에서 붕괴 지점은 어디인가?
- [ ] 붕괴의 정량적 임계점(DO/CT)은 어디인가?

핵심 변수 (Factor Design)

1. **규칙 개수 (`rule_count`)**: 1, 2, 3, 5, 7, 10개
    - ECLIPTICA(단일 규칙)를 확장한 복수 규칙 스트레스 분석.
2. **대화 횟수 (`turn_count`)**: 1, 3, 5, 10, 15, 20번
    - 매 턴 누적 토큰 수(Context Size)를 동시 기록하여 연속적 준수율 추이 분석.
3. **공격 강도 (`attack_intensity`)**: **무해** vs **Crescendo 스타일 점진적 에스컬레이션** (2단계)
    - 최신 연구 결과를 반영하여 가장 현실적인 공격 패턴으로 고도화.

실험 프레임워크 요약

- **대상 모델**: Llama 3.1 8B (로컬 오픈 소스) + GPT-4o (상용 API)
- **예상 케이스**: 약 500개 미만의 조합
- **분석 방법론**: DO(80% 임계점) / CT(50% 임계점) 로지스틱 곡선 탐지 모델 유지

교수님, 위와 같이 최신 연구 동향을 반영하여 실험 설계를 보완하였습니다. 이 방향으로 진행해도 될지 확인 부탁드립니다.